

DETECTAREA CANCERULUI MAMAR UTILIZAND PROCESAREA IMAGINIILOR

Ghiran Lorena

Grupa 30131

Documetatie pe tema “Detectarea cancerului mamar utilizand procesarea imaginilor”

A. Studiul bibliografic

I. Articole care vizeaza prelucrarea imaginilor medicale

1. Research in Medical Imaging Using Image Processing Techniques, Yousif Mohamed Y. Abdallah and Tariq Alqahtani

Pentru procesarea de imagine, imaginea trebuie sa fie binara (alb-negru) deoarece imaginile alb-negru sunt in mod logic o matrice, iar dimensiunea matricii este dimensiunea imaginii reprezentate in pixeli. Fiecare pixel al imaginii este reprezentat ca un nivel discret intre 0-255 si are o pozitie si o valoare specifica.

Pentru a procesa o imagine trebuie sa parcurgem niste pasi. Convertim imaginea in scala gri, normalizam, diminuam zgomotul imaginii folosind diferite filtre, eliminam portiunile nedorite din imagine.

Sunt mai multe tehnici de procesare a imaginilor.

Obiectivul segmentarii este impartirea imaginilor in portiuni importante. Segmentarea locala se ocupa cu partitii imaginilor in parti mici de imagini. Segmentarea globala se ocupa de asamblarea acestor partitii. Segmentarea imaginii functioneaza in 3 metode: region, border si edge.

2. Lucrare de laborator scrisă de TĂRĂȚĂ MIHAI (2010) pentru disciplina Informatică medicală, în care este prezentată procesarea imaginilor medicale.

Memorarea imaginilor medicale este realizata cu fișiere DICOM care pe lângă imaginea în sine oferă informații și despre mărime, dimensiuni, adâncime, setări ale echipamentului. Pentru citirea acestor informații se folosește funcția ‘dicominfo’ din MATLAB.

Filtrarea imaginilor

Pentru filtrarea imaginilor se poate utiliza :

- filtrarea prin determinarea medianei
- filtrarea liniara Gaussiană

Filtrarea prin determinarea medianei este o tehnică de netezire a imaginii prin eliminarea zgomotului. Mediana reprezintă valoarea numerică ce separă întregul set în două jumătăți : inferioară dacă valorile sunt mai mici decât valoarea mediană și superioară în caz contrar.

Pentru a determina valoarea mediană, dacă setul conține un număr impar de elemente, atunci este valoarea de mijloc, iar dacă există un număr par, valoarea mediană este media aritmetică a celor două elemente din mijloc.

Un lucru important în ceea ce privește filtrarea imaginilor este reprezentat de conturul imaginilor. Acesta este un element considerat critic în cadrul unei imagini, de aceea trebuie păstrat neafectat pe cât posibil.

Operații morfologice

Operatorii morfologici sunt utili în particular pentru analiza imaginilor binare. Aceștia sunt:

- eroziune – fiecare pixel al obiectului care atinge un pixel al fundalului se schimbă într-un pixel de fundal
- dilatare- fiecare pixel al fundalului care atinge un pixel dintr-un obiect este schimbat într-un pixel din obiect

Segmentarea

Pentru imaginile cu caracter medical au fost propuse mai multe metode de segmentare : valoarea de prag sau histograma necesită intervenția umană.

Conturul este ansamblul pixelilor obiectului care au cel puțin un vecin în afara obiectului.

Segmentarea prin această metodă constă în localizarea pixelilor care corespund conturilor obiectelor prezente în acea imagine.

Dezavantaje: dificultatea metodei de a defini un contur într-o imagine

Histograma- distribuția nivelurilor de gri în cazul imaginilor în tonuri de gri sau a nivelelor celor trei canale în cazul imaginilor RGB (red, green, blue)

Avantaj: apreciere rapidă a pașilor necesari pt. îmbunătățirea calității imaginii

O prelucrare clasică a imaginilor digitale este reprezentată de îmbunătățirea contrastului prin egalizarea histogramelor.

3. Medical Image Processing : A review – Navnish Goel , Dr. Akhilendra Yadav, Dr. Brij Moham Singh

Imaginile medicale întâmpină o mulțime de zgomote precum : Gaussian, Poisson, Rician și impuls (salt and pepper noise).

Prezența zgomotului de tip impuls poate cauza pierderi ale detaliilor imaginii.

Scopul eliminării zgomotelor este de a elimina zgomotele, dar de a păstra muchiile și detaliile imaginii pe cât posibil.

Radiografiile sunt de obicei afectate de zgomot poisson.

Imaginile cu ultrasunete (ecografie) sunt afectate de zgomot speckle

4. Medical Image Analysis – Felix Ritter, Tobias Boskamp, Andre Homeyer, Hendrik Laue, Michael Schwier, Florian Link si Heinz- Otto Peitgen

Cunostintele legate de absorbtia radiatiilor de catre diferite materiale ajuta la separarea tesutului care are o valoare de +30 HU(Hounsfield units) de aer, care are o valoare -1000 HU.

Aceasta separare este cea mai de baza forma de segmentare si este realizata cu ajutorul unei valori de prag. Deseori, însă, radiodensitatea materialelor nu difera suficient de mult pentru a fi diferențiate doar prin utilizarea pragului. De exemplu, valoarea HU a sângelui este în jur de +40 HU și valoarea țesutului hepatic este cuprinsă între +40 și +60 HU. Percepția structurilor vasculare pline de sânge în interiorul ficatului ar fi dificilă, dacă nu imposibila, având în vedere o diferență atât de mică.

Acesta este motivul pentru care agentii de contrast sunt importanti. Atunci cand sunt aplicati unui pacient, acestia vor schimba caracteristicile imagistice ale structurilor vizate. Utilizarea unui agent de contrast pentru structurile vasculare va creste valoarea HU a sangelui semnificativ peste valoarea tesutului inconjurator (+120 HU).

In general, imaginile medicale contin zgomot. Netezirea imaginii poate ajuta in acest caz, dar va reduce de asemenea perceptia si detectarea conturilor. Netezirea se poate baza pe o operatie fundamentala a imaginii numita convolutie.

Convolutia inlocuieste fiecare voxel cu o suma ponderata a vecinilor sai. Ponderile sunt specificate de nucleul de convolutie, care poate fi reprezentat printr-o matrice. Cel mai de baza nucleu de netezire inlocuieste fiecare voxel cu media ponderata a vecinilor directi, deci va contine o valoare de 1 in toate elementele unei matrici 3X3. Mai comuna este insa utilizarea unui nucleu de convolutie binomial (asemanator cu cel Gaussian) care aplica ponderi mai mari vecinilor mai putin indepartati.

In continuare a fost prezentata procesarea imaginilor medicale cu ajutorul IDE-ului MeVisLab.

MeVisLab contine o biblioteca completa, extensibila de componente functionale, denumite module, pentru segmentare, inregistrare si analize morfologice cantitative, precum si analize functionale. Aceste module pot fi combinate pentru a forma retele de module care implementeaza sarcini complexe de procesare si vizualizare a imaginilor.

MeVisLab utilizeaza o abordare grafica de programare pentru dezvoltarea unor astfel de retele, care permite dezvoltatorului sa instantieze module intr-o retea si sa realizeze conexiuni la distanta pentru a defini fluxul de date si informatiile de control.

5. Ultrasonography based lung cancer screening system Roxana Rusu-Both, Eva-H. Dulf and Romeo I. Chira

Preprocesarea imaginilor cu ultrasunete consta in extragerea regiunii de interes si utilizare unor algoritmi de segmentare pentru detectarea cat mai exacta a zonei de interes. Stabilirea indicilor de analiza de baza pe cateva criterii elaborate de catre autori pentru a diferentia cancerul pulmonar de tumorile benigne. Iar stabilirea indicilor de diagnostic se bazeaza pe analiza retelei neuronale si evaluarea indicilor de analiza determinati anterior.

Pentru a determina indicii avem nevoie de: indicele de netezire a conturului, indicele de forma, indicele ratei de tranzitie a intensitatii pixelului de contur, indicele petelor albe din interior.

6. Lung Cancer Detection Using Image Segmentation by means of Various Evolutionary Algorithms, K. Senthil Kumar ,1 K. Venkatalakshmi ,2 and K. Karthikeyan 3

Filtrul median elimina zgomotul si pastreaza claritatea imaginii. In conformitate cu numele fiecare pixel este inlocuit cu valoarea medie de pixeli din apropiere. Acesta este unul dintre cele mai bune filtre intre filtrele conventionale care indepartaza zgomotul. In filtrul median adaptiv, dimensiunea ferestrei variaza in functie de fiecare pixel.

Filtru average, este un filtru simplu care elimina zgomotul spațial dintr-o imagine digitală. Prezența zgomotului spațial se datorează în principal procesului de achiziție a datelor.

Valoarea medie de vecinătate este măsurată pentru fiecare pixel și este înlocuită de valoarea medie corespunzătoare. Acest proces se repetă pentru fiecare pixel din imagine. Toți pixelii din imaginea digitală sunt modificați prin glisarea operatorului pe întreaga gamă de pixeli.

Histogram Equalization

Îmbunătățirea imaginii este tehnica folosită pentru îmbunătățirea calității imaginii. Pentru o mai bună înțelegere și analiză, este obligatorie îmbunătățirea contrastului imaginilor medicale. Metoda obișnuită folosită în funcție de echivalare a ististicii. O mică ajustare a intensității pixelilor de imagine se face în această metodă. Fiecare pixel este mapat la intensitate proporțională cu rangul său în pixelii din jur.

7. Hyperspectral Image Processing for Automatic Target Detection Applications

Dimitris Manolakis, David Marden, and Gary A. Shaw

Acest articol prezintă o imagine de ansamblu a problemelor teoretice și practice asociate cu dezvoltarea, analiza și aplicarea algoritmilor de detecție pentru a exploata datele imagistice hiperspectrale. Se concentreaza pe tehnici care exploatează informația spectrală exclusiv pentru a lua decizii cu privire la tipul fiecărui pixel si forma spatiaala.

Spacial processing

- Informațiile sunt încorporate în aranjamentul spațial al pixelilor din fiecare bandă spectrală (imagine cu două dimensiuni)

- Prelucrarea imaginilor exploatează informațiile geometrice de formă
- Rezoluție spațială foarte mare necesară pentru identificarea obiectelor după formă (mulți pixeli pe țintă)
- Rezoluția spațială ridicată necesită diafragme mari și duce la raport scăzut semnal-zgomot
- Volumul datelor crește odată cu pătratul rezoluției spațiale
- Succes limitat în dezvoltarea algoritmilor de exploatare a funcțiilor spațiale complet automatizate

Spectral Processing

- Fiecare pixel are un spectru asociat care poate fi utilizat pentru a identifica materialele din celula de rezoluție la sol corespunzătoare
- Procesarea se poate face cu un pixel la un moment dat
- Nu este nevoie de rezoluție spațială ridicată (un pixel pe țintă)
- Rezoluția spectrală mai importantă decât rezoluția spațială Volumul datelor crește liniar cu numărul benzilor spectrale
- Algoritmi complet automatizați pentru exploatarea caracteristicilor spectrale au fost dezvoltați cu succes pentru aplicațiile selectate

8. Image processing using artificial neural networks by Alexandrina-Elena Pandeale* , Mihai Budescu and Gabriela Covatariu

ANN (Artificial Neuronal Networks)

Procesarea imaginilor folosind rețele neuronale artificiale a fost folosită cu succes în diferite domenii. Preprocesarea imaginii, reducerea datelor, segmentarea și recunoașterea sunt procesele utilizate în gestionarea imaginilor cu ANN. O imagine poate fi reprezentată ca o matrice, fiecare element al matricei conținând informații despre culoare pentru un pixel. Matricea este utilizată ca date de intrare în rețeaua neuronală. Dimensiunile mici ale imaginilor, pentru a ajuta cu ușurință și rapiditate la învățare, stabilesc dimensiunea vectorului și numărul de vectori de intrare. Funcția de transfer folosită este o funcție sigmoidală. Rata de învățare include valori cuprinse între $[0,1]$ și eroarea, pentru care este recomandat să fie sub 0,1.

Cuvinte cheie: rețele neuronale artificiale; imagini digitale și prin satelit; preprocesarea imaginii; reducerea datei; segmentare; recunoaștere.

Prezinta probleme din diferite domenii care au fost rezolvate utilizand ANN.

Probleme in domeniul medical rezolvate folosind ANN

Procesarea lentă a filmelor, modificarea imaginii, limitarea expunerii la radiografii, diagnosticarea greșită prin analizarea imaginilor scanate din cauza anomaliilor (zgomotul speckle) la scanări cu ultrasunete, imagini RMN, CT, SUA, artefactele au fost motivele care au fost studiate pentru rezolvarea acestor probleme. Astfel, problema a fost rezolvată prin implementarea unui

algoritm pentru segmentarea imaginii cu filtre wavelets și ANN care detectează, în timp real, diagnosticul.

9. Neural Networks for Image Recognition: Methods, Best Practices, Applications

Am ajuns la concluzia ca cel mai eficient instrument folosit pentru image recognition îl reprezintă neural networks. NN este o arhitectură concepută pentru a procesa, corela și înțelege cantitatea mare de date din imagini de înaltă rezoluție.

Un tip de algoritm de recunoaștere a imaginilor este un image classifier. Acesta ia o imagine (sau o parte dintr-o imagine) ca o intrare și prezice ce conține imaginea.

Etapele de pre-procesare a datelor imagine pentru rețelele neuronale:

- Algoritmii neuronali de recunoaștere a imaginilor din rețea se bazează pe calitatea setului de date - imaginile utilizate pentru antrenarea și testarea modelului. Iată câțiva parametri și considerații importante pentru pregătirea datelor de imagine.
- Dimensiunea imaginii - o imagine de calitate superioară oferă modelului mai multe informații, dar necesită mai multe noduri de rețea neuronale și mai multă putere de procesare.
- Numărul de imagini - cu cât alimentați mai multe date unui model, cu atât va fi mai precis, dar asigurați-vă că setul de instruire reprezintă populația reală.
- Numărul de canale - imaginea la nivel de gri are 2 canale (alb-negru), iar imaginile color au de obicei 3 canale color (Roșu, Verde, Albastru / RGB), cu culori reprezentate în intervalul [0,255].
- Raportul de aspect - asigurați-vă că imaginile au același raport și dimensiune. De obicei, modelele de rețea neuronală presupun o imagine de intrare de formă pătrată.
- Scalarea imaginii - odată ce toate imaginile sunt pătrate, puteți scala fiecare imagine. Există multe tehnici de scalare și coborâre în jos, care sunt disponibile ca funcții în bibliotecile de învățare profundă.
- Media, abaterea standard a datelor de intrare - puteți privi „imaginea medie” calculând valorile medii pentru fiecare pixel, în toate exemplele de formare, pentru a obține informații despre structura de bază din imagini.
- Normalizarea intrărilor de imagine - se asigură că toți parametrii de intrare (pixeli în acest caz) au o distribuție uniformă a datelor. Acest lucru face ca convergența să fie mai rapidă atunci când antrenați rețeaua. Puteți efectua normalizarea datelor scăzând media din fiecare pixel și apoi împărțind rezultatul la abaterea standard.
- Reducerea dimensionalității - puteți decide să prăbușiți canalele RGB într-un canal la scară gri. S-ar putea să doriți să reduceți alte dimensiuni dacă intenționați să faceți

rețeaua neuronală invariabilă la acea dimensiune sau să faceți antrenamentul mai puțin intens din punct de vedere computerizat.

Mărirea datelor - implică mărirea setului de date existent, cu tipuri perturbate de imagini curente, inclusiv scalare și rotire. Faceți acest lucru pentru a expune rețeaua neuronală la o varietate de variații. În acest fel, această rețea neuronală este mai puțin probabil să identifice caracteristicile nedorite în setul de date.

10. Surface defect detection in tiling Industries using digital image processing methods: Analysis and evaluation Mohammad H. Karimi, Davud Asemanin

Algoritmi de detecție a defectelor pentru produse ceramice și faianță

Filtering approaches

Aici sunt utilizate în general transformări matematice și filtre. În acest sens, pot fi utilizate atât transformări liniare, cât și neliniare. Cei mai importanți algoritmi includ transformarea Wavelet și Counterlet, analiza independentă a componentelor, analiza Gaborfiltrare și rețelele neuronale artificiale.

Transformarea Wavelet

În fiecare etapă, imaginea de intrare este împărțită în patru subimagini. Transformarea Wavelet a fost utilizată pentru pre-prelucrare și extragerea caracteristicilor de textură.

Genetic algorithm, Analiza independenta a componentelor, Artificial Neural Networks, Gabor filter, Structural approaches, Morphological methods, Edge detection algorithms etc.

Acest articol prezinta atat metodele cat si filtrele folosite in procesarea de imagine. Prezinta metode de detectare a defectelor de suprafata cu avantaje si dezavantaje.

11. Edge Detection Methods in Digital Image Processing, You-yi Zheng, Ji-lai Rao, Lei Wu

Edge detection este una dintre metodele bazate pe segmentarea marginilor.

Există numeroase moduri de detectare a marginilor: metoda operatorului diferențial; morfologie matematică; Metoda de urmărire cu franjuri, etc. Această lucrare descrie metoda operatorului diferențial și metoda morfologiei matematice și în conformitate cu nevoile de măsurare - detectarea marginilor subțiri, în cele din urmă, și alege operatorul Canny și metoda morfologică matematică pentru a fi comparate, în funcție de rezultatele testelor pentru a determina cea mai bună metodă.

12. Algorithm for Image Processing Using Improved Median Filter and Comparison of Mean, Median and Improved Median Filter Gajanand Gupta

Operațiile de procesare a imaginilor pot fi împărțite aproximativ în trei mari categorii: comprimarea imaginii, îmbunătățirea și restaurarea imaginii, extragerea măsurătorilor.

Sunt prezentați pașii pentru algoritmul pentru filtrul median îmbunătățit. Compară filtrul mediu și îmbunătățit cu filtrul median îmbunătățit.

Filtrul se bazează pe filtrarea statistică a comenzilor și folosește un detector de zgomot impulsiv.

Performanța bună a filtrului median standard este afectată grav de zgomotul extrem de impulsiv. Aspectele inovatoare ale metodei studiate sunt un algoritm simplu și eficient de anulare a zgomotului într-o gamă largă de densități de zgomot între 10% și 98%, păstrând în același timp o calitate ridicată a imaginii restaurate. Succesul cheie al unei astfel de prestări de performanță se datorează în principal detectării zgomotului extrem de precise prin acest algoritm. În plus, metoda studiată folosește o fereastră simplă cu lungime fixă și, prin urmare, necesită un timp de procesare semnificativ mai mic în comparație cu alte metode. Rezultatele de simulare arată că metoda studiată poate fi aplicată la diferite tipuri de imagine și oferă rezultate foarte satisfăcătoare. Are îmbunătățiri semnificative față de metodele existente.

13. Efficient Cancer Detection Using Multiple Neural Networks, John Shell and William D. Gregory

Este prezentat modelul matematic și explicate metodele și algoritmul pentru detectarea cancerului utilizând rețele neuronale.

Problemele de învățare automată care implică vectori care nu sunt separați liniar pot necesita unul sau mai multe straturi ascunse suplimentare pentru o capacitate de calcul sporită, fiind denumite perceptri multistrat (MLP)

Cele șase MLP-uri de propagare alese pentru această implementare sunt:

- 1) Coborâre gradientă, cu impuls și ritm de adaptare adaptativ la rata de învățare
- 2) Backpropagation Levenberg-Marquardt
- 3) Backpropagation rezistent
- 4) Backpropagation gradient conjugat la scară
- 5) Backpropagation de gradient conjugat cu Powell-Beale repornește
- 6) Backpropagation gradient conjugat cu actualizări Fletcher-Reeves.

14. Plant Disease Detection using Image Processing – Sachin D. Khirade

In aceasta lucrare este prezentata importanta depistarii bolilor plantelor si rezultatele bazate pe utilizarea procesarii imaginilor. Descoperirea unei boli a plantelor este foarte critica pentru agricultura si este greu de detectat manual, deoarece necesita expertiza in domeniul bolilor plantelor, mult timp pentru a investiga si un ochi ager pentru a observa o asemenea problema.


Acesta este motivul pentru care in aceasta lucrare au fost prezentate metodele utilizate pentru detectarea bolilor folosind imagini cu frunze.

Deoarece este dificil sa se lucreze cu imagini RGB, acestea au fost transformate in imagini gri. Apoi, egalizarea histogramei este aplicata pe imagine pentru a imbunatati imaginile bolii plantelor.

Alti specialisti au utilizat o retea neuronal artificiala pentru detectare bolii, creand 2 baze de date, una pentru antrenarea imaginilor bolii deja stocate si alta pentru implementarea imaginilor de interogare. Apoi, back propagation este folosita pentru bazele de date de instruire si au fost considerati trei vectori de caracteristici, reiesind ca vectorul cu caracteristica morfologica da rezultate mai bune.

Preprocesarea se face folosind filtrarea Fourier, detectarea muchiilor si aplicarea operatiilor morfologice.

Segmentarea imaginilor este realizata cu algoritmul k-means si pragul Otsu, insa algoritmul k-means da rezultate mai bune.



-Achizitia imaginii- imaginile frunzei plante sunt realizate de o camera foto, iar acele imagini sunt in forma RGB(Rosu, Verde, Albastru). Acesta este motivul pentru care este creata transformarea culorii pentru imagine

-Preprocesarea imaginii – Pentru a elimina zgomotul din imagine sunt necesare tehnici de preprocesare. De exemplu, taierea regiunii de interes a imaginii, netezirea, contrastarea sau una dintre cele mai importante etape ale preprocesarii este transformarea imaginii RGB intr-o imagine gri

-Segmentarea imaginii – selecteaza diferite parti care impartasesc aceleasi caracteristici sau prezinta o oarecare asemanare in imagine

-Extragerea trasaturilor – importanta daca se doreste gasirea unui obiect specific. Cele mai

frecvente trasaturi sunt culoarea, textura, morfologia, marginile etc.(exista rezultate care atesta ca trasaturile morfologice indica cele mai bune rezultate)

- Detectare si clasificarea – dupa extragerea caracteristicilor, imaginile bazei de date de invatare sunt clasificate . Reteaua neuronală este instruita pentru a putea clasifica si imaginile noi care nu au fost furnizate in baza de date de invatare.

B. Program



- Sânul este aproape în întregime gras. Mamografia este extrem de sensibilă în acest cadru.
- Există zone dispersate de densitate glandulară fibroasă. Termenul densitate descrie gradul de atenuare cu raze X a țesutului mamar, dar nu descoperiri mamografice discrete.
- Sânii sunt eterogen densi, ceea ce poate ascunde masele mici. Unele zone ale sânilor sunt suficient de dense pentru a ascunde masele mici.
- Sânii sunt extrem de densi, ceea ce reduce sensibilitatea mamografiei.

Forma: ovală (poate include 2 sau 3 lobulații), rotundă sau neregulată

Marje: circumscrise, ascunse, micro lobulate, indistincte, speculate

Densitate: mare, egală, scăzută sau conținând grăsimi.

Imaginile arată o leziune care conține grăsime cu o calcificare asemănătoare floricelelor. Toate leziunile care conțin grăsime sunt de obicei benigne. Aceste descoperiri ale imaginii sunt diagnostice pentru ahematom - cunoscut și sub numele de fibroadenolipom.

Metoda:

Sistemul general cuprinde 4 etape, prima este achiziționarea imaginii, a doua extragerea caracteristicilor din mamografia, selectarea mai multor caracteristici optime, clasificatorul pentru identificarea clasei adecvate de mamografie și Transformarea undelor discrete pentru segmentare. Părțile suspecte au fost extrase din mamografie utilizând textura caracteristici. Caracteristicile texturii sunt extrase folosind GLCM de-a lungul 0° pentru fiecare mamografie. Funcțiile reprezintă imaginea într-un format specific care se concentrează în special pe informațiile relevante. În etapa următoare sunt selectate caracteristici pentru instruire și testare; Această etapă este foarte importantă, deoarece acuratețea clasificării depinde în principal de selecția atentă a caracteristicilor. În celălalt pas mamografiile sunt clasificate, pentru această rețea neuronală este utilizată ca clasificator. Mai exact, să distingem mamografia și să o clasificăm în clasă normală și malignă.

